

تمرین‌های درس داده‌کاوی

مصطفی سبیلو (۱۰۸۲۵۴)

مهندی محمدی (۱۱۰۹۴)

فصل ۴

تمرین ۱

(الف)

مرحله ۱:

تعداد تکرار هر آیتم در تراکنش‌ها را نسبت به تعداد کل تراکنش‌ها محاسبه می‌کنیم.

	درصد	پشتیبان (Support)	آیتم	ردیف
	۲۰	۱ — ۵	A	۱
	۴۰	۲ — ۵	C	۲
	۲۰	۱ — ۵	D	۳
✓	۸۰	۴ — ۵	E	۴
	۲۰	۱ — ۵	I	۵
✓	۱۰۰	۵ — ۵	K	۶
✓	۶۰	۳ — ۵	M	۷
	۴۰	۲ — ۵	N	۸
✓	۶۰	۳ — ۵	O	۹
	۲۰	۱ — ۵	U	۱۰
✓	۶۰	۳ — ۵	Y	۱۱

مرحله ۲:

از مرحله ۱ اقلامی که پشتیبان ۶۰ درصد و بیشتر از ۶۰ درصد دارند را انتخاب می‌کنیم. مجموعه اقلام ۲ تایی از آن‌ها می‌سازیم و مجدد پشتیبان را برای این مجموعه جدید محاسبه می‌کنیم.

	درصد	پشتیبان (Support)	آیتم	ردیف
✓	۸۰	۴ — ۵	E, k	۱
	۴۰	۲ — ۵	E, M	۲
✓	۶۰	۳ — ۵	E, O	۳
	۴۰	۲ — ۵	E, Y	۴
✓	۶۰	۳ — ۵	K, M	۵
✓	۶۰	۳ — ۵	K, O	۶
✓	۶۰	۳ — ۵	K, Y	۷
	۲۰	۱ — ۵	M, O	۸
	۴۰	۲ — ۵	M, Y	۹
	۴۰	۲ — ۵	O, Y	۱۰

مرحله ۳:

با اقلام ۲ تایی از مرحله ۲ که پشتیبان برابر یا بیشتر از ۶۰ درصد دارند و اقلامی که از مرحله ۱ قبل انتخاب شده‌اند، مجموعه اقلام ۳ تایی می‌سازیم و پشتیبان را برای این مجموعه اقلام ۳ تایی محاسبه می‌کنیم.

	درصد	پشتیبان (Support)	آیتم	ردیف
	۴۰	۲ — ۵	E, K, M	۱
✓	۶۰	۳ — ۵	E, K, O	۲
	۴۰	۲ — ۵	E, K, Y	۳
	۲۰	۱ — ۵	E, M, O	۴
	۴۰	۲ — ۵	E, O, Y	۵
	۲۰	۱ — ۵	K, M, O	۶
	۴۰	۲ — ۵	K, M, Y	۷
	۴۰	۲ — ۵	K, O, Y	۸

#### مرحله ۴:

با اقلام ۳ تایی از مرحله ۳ که پشتیبان برابر یا بیشتر از ۶۰ درصد دارند و اقلامی که از مرحله ۱ قبل انتخاب شده‌اند، مجموعه اقلام ۴ تایی می‌سازیم و پشتیبان را برای این مجموعه اقلام ۴ تایی محاسبه می‌کنیم.

	درصد	پشتیبان (Support)	آیتم	ردیف
	۲۰	$\frac{۱}{۵}$	E, K, M, O	۱
	۴۰	$\frac{۲}{۵}$	E, K, O, Y	۲

در این مرحله چون هیچ مجموعه اقلام ۴ تایی پشتیبان برابر یا بیشتر از ۶۰ درصد ندارد، بنابراین الگوریتم متوقف می‌شود.

نتیجه نهایی:

$\{\{E\}, \{K\}, \{M\}, \{O\}, \{Y\}, \{E, K\}, \{E, O\}, \{K, M\}, \{K, O\}, \{K, Y\}, \{E, K, O\}\}$

(ب)

مرحله ۱:

برای هر آیتم، پشتیبان (support) را محاسبه می‌کنیم:

درصد	پشتیبان (support)	آیتم	ردیف
۶۰	$\frac{۳}{۵}$	M	۱
۶۰	$\frac{۳}{۵}$	O	۲
۴۰	$\frac{۲}{۵}$	N	۳
۱۰۰	$\frac{۵}{۵}$	K	۴
۸۰	$\frac{۴}{۵}$	E	۵
۶۰	$\frac{۳}{۵}$	Y	۶
۲۰	$\frac{۱}{۵}$	D	۷
۲۰	$\frac{۱}{۵}$	A	۸
۲۰	$\frac{۱}{۵}$	U	۹
۴۰	$\frac{۲}{۵}$	C	۱۰
۲۰	$\frac{۱}{۵}$	I	۱۱


مرحله ۲:



در هر تراکنش آیتم‌هایی که مقدار پشتیبان زیر ۶۰ درصد دارند را حذف می‌کنیم و آیتم‌های باقی مانده را به ترتیب مقدار پشتیبان محاسبه شده در مرحله قبل به صورت نزولی مرتب می‌کنیم:



#	TID	Items_bought
1	T100	{K, E, M, O, Y}
2	T200	{K, E, O, Y}
3	T300	{K, E, M}
4	T400	{K, M, Y}
5	T500	{K, E, O}

مرحله ۳:

درخت FP-tree را ایجاد می‌کنیم؛ به این صورت که یک گره با مقدار null ایجاد می‌کنیم. سپس برای هر تراکنش یک شاخه به گره null اضافه می‌کنیم:







مرحله ۴:

پایگاه الگوهای شرطی را ایجاد می‌کنیم.

برای هر آیتم Conditional Pattern Base را ایجاد می‌کنیم:

#	Item	Conditional Pattern Base (CPB)
1	Y	{K, E, M, O: 1}, {K, E, O: 1}, {K, M: 1}
2	O	{K, E, M: 1}, {K, E: 2}
3	M	{K, E: 2}, {K: 1}
4	E	{K: 4}

در پایگاه داده جدید ساخته شده مجدد برای هر تراکنش، بازی هر آیتم در ستون CPB، پشتیبان را محاسبه کرده و آیتم‌هایی که پشتیبان کمتر از ۶۰ درصد دارند را حذف می‌کنیم:

#	Item	Conditional Pattern Base (CPB)	Conditional FP-tree
1	Y	{K, E, M, O: 1}, {K, E, O: 1}, {K, M: 1}	K: 3
2	O	{K, E, M: 1}, {K, E: 2}	K: 3, E: 3
3	M	{K, E: 2}, {K: 1}	K: 3
4	E	{K: 4}	K: 4

در آخر ترکیب اقلام ستون Item را با ستون Conditional FP-tree تولید می‌کنیم:

#	Item	CPB	Conditional FP-tree	Frequent Pattern Generated
1	Y	{K, E, M, O: 1}, {K, E, O: 1}, {K, M: 1}	K: 3	{K, Y}
2	O	{K, E, M: 1}, {K, E: 2}	K: 3, E: 3	{K, Y}, {E, Y}, {K, E, Y}
3	M	{K, E: 2}, {K: 1}	K: 3	{K, M}
4	E	{K: 4}	K: 4	{K, E}

جواب نهایی شامل اقلام محاسبه شده در مرحله اول و Frequent Pattern Generated هستند:

$\{\{K\}, \{E\}, \{M\}, \{O\}, \{Y\}, \{E, K\}, \{E, O\}, \{K, M\}, \{K, O\}, \{K, Y\}, \{E, K, O\}\}$

(پ)  
رابطه:

$$\forall x \in transaction, buys(X, item_1) \wedge buys(X, item_2) \Rightarrow buys(X, item_3)$$

باید سه آیتمی را انتخاب کنیم که:

$$item_1, item_2 \rightarrow item_3$$

برای اینکه در رابطه بالا حداقل مقدار پشتیبان (minsup) را داشته باشیم، باید زیرمجموعه‌هایی<sup>۳</sup> تایی از مجموعه ۱۱ آبتم بیابیم که حداقل مقدار پشتیبان را داشته باشند. تنها مجموعه  $\{E, K, O\}$  حداقل مقدار پشتیبان (۶۰ درصد) را دارد. بنابراین مقدار minconf زیرمجموعه‌های دو عضوی از مجموعه  $\{E, K, O\}$  را محاسبه می‌کنیم:

$$conf(E, K \Rightarrow O) = \frac{3}{4} = 75\%$$

$$conf(K, O \Rightarrow E) = \frac{3}{3} = 100\%$$

$$conf(E, O \Rightarrow K) = \frac{3}{3} = 100\%$$

## تمرین ۲

### (الف)

ابتدا تراکنش‌ها را براساس کالا بازنویسی می‌کنیم:

TID	Items_bought
T100	{Crab, Milk, Cheese, Bread}
T200	{Cheese, Milk, Apple, Pie, Bread}
T300	{Apple, Milk, Bread, Pie}
T400	{Bread, Milk, Cheese}

سپس الگوهای مکرر را براساس حداقل مقدار پشتیبان (minsup) یعنی ۶۰ درصد پیدا می‌کنیم (برای مثال از روش Apriori  $\{\{Milk: 100\%\}, \{Cheese: 75\%\}, \{Bread: 100\%\}, \{Milk, Cheese: 75\%\}, \{Milk, Bread: 100\%\}, \{Cheese, Bread: 75\%\}, \{Milk, Cheese, Bread: 75\%\}\}$

مشاهده می‌شود که مجموعه اقلام<sup>۳</sup> تایی بزرگ‌ترین مجموعه اقلام است؛ بنابراین برای حالت‌های مختلف مقدار پشتیبان و مقدار اطمینان را براساس قانون کلی زیر محاسبه می‌کنیم:

$$\forall x \in transaction, buys(X, item_1) \wedge buys(X, item_2) \Rightarrow buys(X, item_3)$$

#	Rule	Support	Confidence
1	Milk, Cheese -> Bread	75 %	100 %
2	Milk, Bread -> Cheese	75 %	75 %
3	Cheese, Bread -> Milk	75 %	100 %

بنابراین دو قانون زیر حداقل مقدار پشتیبان (minsup) ۶۰ درصد و حداقل مقدار اطمینان (minconf) ۸۰ درصد را دارند:

Milk, Cheese -> Bread

Cheese, Bread -> Milk

### (ب)

ابتدا مقدار پشتیبان را برای هر برنده-کالا محاسبه می‌کنیم:

{Best-Bread: 25%}, {Best-Cheese: 25%}, {Dairyland-Cheese: 50%}, {Dairyland-Milk: 50%}, {Goldenfarm-Apple: 25%}, {King's-Crab: 25%}, {Sunset-Milk: 50%}, {Tasty-Pie: 50%}, {Westcoast-Apple: 25%}, {Wonder-Bread: 75%}

مشاهده می شود که فقط Wonder-Bread بیشتر از حداقل مقدار پشتیبان است.