

پیش‌بینی دیابت با استفاده از مدل‌های یادگیری ماشین نظارت‌شده

خلاصه

بیماری دیابت یکی از شایع‌ترین، خطرناک‌ترین و پرهزینه‌ترین بیماری‌های حال حاضر دنیا است که با نرخ هشداردهنده‌ای در حال افزایش است. استفاده از روش‌های داده‌کاوی و یادگیری ماشین می‌تواند به تشخیص زودهنگام دیابت کمک کند و از پیشرفت بیماری و بروز عوارضی مانند بیماری‌های قلبی و عروقی، مشکلات بینایی و نارسایی‌های کلیوی جلوگیری نماید. در این تحقیق از کتابخانه scikit-learn برای مدل‌سازی و دسته‌بندی افراد به دو گروه دیابتی و غیر دیابتی استفاده شده است. داده‌های موردنیاز این تحقیق از پایگاه Kaggle استخراج شده و شامل ۱۰۰,۰۰۰ رکورد اولیه از مراجعه‌کنندگان است. ویژگی‌های موجود در این داده‌ها شامل جنسیت، سن، سابقه فشارخون بالا، سابقه بیماری قلبی، سابقه مصرف سیگار، شاخص توده بدنی (BMI)، سطح HbA1c و سطح گلوکز خون می‌باشند.

پس از پاک‌سازی داده‌ها، حذف رکوردهای تکراری، کدگذاری ویژگی‌های دسته‌ای، استانداردسازی ویژگی‌های عددی و متوازن‌سازی داده‌های آموزشی با روش SMOTENC، طبقه‌بند K- Gaussian Naive Bayes (GaussianNB)، AdaBoost، Logistic Regression، Support Vector Machine (SVM)، Nearest Neighbors (KNN) و Decision Tree و Multi-layer Perceptron (MLPClassifier) آموزش داده شدند و مورد ارزیابی قرار گرفتند. نتایج نشان داد که مدل Decision Tree با دقت آزمون ۹۶.۷۵٪ و F1-score برابر ۰.۷۹ برای کلاس دیابت، از نظر عملکرد کلی و تعادل میان معیارها بهترین نتیجه را در میان مدل‌ها داشته است. با این حال، مدل SVM با کرنل RBF با دستیابی به Recall برابر ۹۲٪ برای کلاس دیابت، بیشترین توانایی را در شناسایی بیماران واقعی نشان داد و از دیدگاه غربالگری پزشکی، مدلی حساس‌تر محسوب می‌شود.

۱. مقدمه

دیابت یک بیماری مزمن است که روی چگونگی تولید و استفاده انسولین در بدن اثر می‌گذارد. اگر سلول‌های بدن در مقابل انسولین مقاومت نشان دهند و یا اگر بدن به اندازه کافی انسولین نسازد، عملکرد بدن دچار اختلال خواهد شد. اشخاصی که به بیماری دیابت مبتلا هستند، به‌ویژه در مراحل اولیه، ممکن است علائم فیزیکی چشمگیری نداشته باشند و همین موضوع تشخیص زودهنگام بیماری را دشوارتر می‌کند. مسئله قابل‌توجه در حوزه پزشکی آن است که هنگامی که تعداد پارامترهای موردبررسی زیاد باشد، تشخیص صحیح حتی برای یک متخصص هم دشوار می‌شود. از طرفی کشف الگوهای پنهان و ارتباط میان پارامترهای تأثیرگذار بر بیماری به روش‌های سنتی تقریباً ناممکن است؛ بنابراین هدف اصلی این تحقیق کشف ارتباط میان عوامل تأثیرگذار و ایجاد مدلی هوشمند برای پیش‌بینی بیماری است.

در این پژوهش، مسئله به‌صورت یک طبقه‌بندی دودویی در نظر گرفته شده است؛ به این معنا که هر نمونه تنها به یکی از دو کلاس «غیر دیابتی» و «دیابتی» تعلق دارد. بنابراین هدف مدل‌ها، پیش‌بینی وجود یا عدم وجود دیابت بر اساس ویژگی‌های فردی و آزمایشگاهی موجود در دیتاست است، نه تشخیص نوع دیابت.

۲. مفاهیم پایه

۱.۲ نقشه‌های حرارتی همبستگی

نقشه حرارتی همبستگی یک ابزار مفید برای نمایش گرافیکی چگونگی ارتباط دو ویژگی با یکدیگر است. بسته به نوع داده ویژگی‌ها، باید از روش‌های محاسبه ضریب همبستگی مناسب استفاده کنیم. به‌عنوان مثال می‌توان به ضریب همبستگی پیرسون اشاره کرد. ضریب همبستگی پیرسون معیاری از همبستگی خطی بین دو مجموعه داده است. نسبت بین کوواریانس دو متغیر و حاصل‌ضرب انحراف معیار آن‌هاست؛ بنابراین اساساً یک اندازه‌گیری نرمال شده از کوواریانس است، به‌طوری‌که نتیجه همیشه مقداری بین -۱ و +۱ دارد.

۲.۲ معیارهای ارزشیابی

یک ماتریس درهم‌ریختگی چیدمان جدولی خاصی است که اجازه تجسم عملکرد یک الگوریتم یادگیری نظارت‌شده را می‌دهد. هر ردیف از ماتریس نشان‌دهنده نمونه‌ها در یک کلاس واقعی است درحالی‌که هر ستون نشان‌دهنده نمونه‌ها در یک کلاس پیش‌بینی‌شده است. جدول زیر مثالی از یک ماتریس درهم‌ریختگی برای یک طبقه‌بندی دودویی است که اصطلاحات/معیارهای دیگر را می‌توان از آن استخراج کرد.

	Predicted 0	Predicted 1
Actual 0	TN	FP
Actual 1	FN	TP

عبارت	معنی	توضیحات
TP	مثبت صحیح	موارد مثبتی که به‌عنوان مثبت پیش‌بینی شده‌اند.
FP	مثبت کاذب	موارد منفی که به‌عنوان مثبت پیش‌بینی شده‌اند.
TN	منفی صحیح	موارد منفی که به‌عنوان منفی پیش‌بینی شده‌اند.
FN	منفی کاذب	موارد مثبتی که به‌عنوان منفی پیش‌بینی شده‌اند.

۱. **Accuracy**: اندازه‌گیری تعداد مواردی که به‌درستی توسط مدل شناسایی/پیش‌بینی شده‌اند، یعنی پیش‌بینی صحیح تقسیم‌بر حجم کل نمونه.

$$\frac{TP + TN}{TP + TN + FP + FN}$$

۲. **Recall**: نرخ موارد مثبت صحیح را اندازه‌گیری می‌کند، یعنی چند مورد از موارد مثبت واقعی توسط مدل به‌عنوان مثبت شناسایی/پیش‌بینی می‌شوند.

$$\frac{TP}{(TP + FN)}$$

۳. **Precision**: اندازه‌گیری می‌کند که چه تعداد از موارد مثبت پیش‌بینی‌شده درواقع مثبت هستند.

$$\frac{TP}{(TP + FP)}$$

۴. **F1-Score**: **Precision** و **Recall** مدل را ترکیب می‌کند و به‌عنوان میانگین هارمونیک **Precision** و **Recall** مدل‌ها تعریف می‌شود.

$$2 \times \frac{recall \times precision}{recall + precision}$$

۵. **ROC**: منحنی مشخصه عملیاتی گیرنده (ROC)، یک نمودار گرافیکی است که عملکرد الگوریتم طبقه‌بندی دودویی را به‌عنوان تابعی از نرخ مثبت صحیح و نرخ مثبت کاذب نشان می‌دهد.

۳. روشی انجام تحقیق

۱.۳ کاوش ویژگی‌ها و هدف

۱.۱.۳ خلاصه آماری

پس از بارگذاری دیتاست اولیه (df0) و نمایش ۱۰ سطر اول (جدول ۱)، ستون‌های موجود و نوع داده‌های آن‌ها با دستورات df0.columns و df0.dtypes بررسی شدند.

جدول ۱ – نمایش ۱۰ سطر اول دیتافریم df0 (داده‌های خام).

Head of raw data:									
	gender	age	hypertension	heart_disease	smoking_history	bmi	bA1c_level	blood_glucose_level	diabetes
0	Female	80.0	0	1	never	25.19	6.6	140	0
1	Female	54.0	0	0	No Info	27.32	6.6	80	0
2	Male	28.0	0	0	never	27.32	5.7	158	0
3	Female	36.0	0	0	current	23.45	5.0	155	0
4	Male	76.0	1	1	current	20.14	4.8	155	0
5	Female	20.0	0	0	never	27.32	6.6	85	0
6	Female	44.0	0	0	never	19.31	6.5	200	1
7	Female	79.0	0	0	No Info	23.86	5.7	85	0
8	Male	42.0	0	0	never	33.64	4.8	145	0
9	Female	32.0	0	0	never	27.32	5.0	100	0

با اجرای دستور df0["diabetes"].value_counts()، توزیع اولیه برچسب هدف نشان داد که در داده خام ۹۱,۵۰۰ نمونه سالم یا غیر دیابتی (کلاس ۰) و ۸,۵۰۰ نمونه دیابتی (کلاس ۱) وجود دارد. پس از حذف رکوردهای تکراری و حذف ۱۸ نمونه با مقدار "Other" در ویژگی جنسیت، تعداد کل نمونه‌های مورد استفاده به ۹۶,۱۲۸ رکورد کاهش یافت. در این داده پاک‌سازی‌شده، تعداد نمونه‌های سالم ۸۷,۶۴۶ و تعداد نمونه‌های دیابتی ۸,۴۸۲ بود. این موضوع نشان‌دهنده عدم توازن شدید میان کلاس‌ها است که یکی از چالش‌های اصلی مدل‌سازی محسوب می‌شود.

برای ویژگی‌های عددی (age, bmi, HbA1c_level, blood_glucose_level)، دستور df1[["age", "bmi", "HbA1c_level", "blood_glucose_level"]].describe() اعمال شد و خلاصه آماری حاصل در جدول ۲ درج گردید.

جدول ۲ – خلاصه آماری ویژگی‌های عددی دیتافریم df1.

Summary of main continuous features:				
	age	bmi	HbA1c_level	blood_glucose_level
count	96128.000000	96128.000000	96128.000000	96128.000000
mean	41.796617	27.321450	5.532633	138.218001
std	22.463329	6.767811	1.073225	40.911190
min	0.000000	10.010000	3.500000	80.000000
25%	24.000000	23.400000	4.800000	100.000000
50%	43.000000	27.320000	5.800000	140.000000
75%	59.000000	29.860000	6.200000	159.000000
max	80.000000	95.690000	9.000000	300.000000

خلاصه آماری ویژگی‌های عددی نشان داد که میانگین سن افراد برابر ۴۱.۸۰ سال، میانگین BMI برابر ۲۷.۳۲، میانگین HbA1c برابر ۵.۵۳ و میانگین سطح گلوکز خون برابر ۱۳۸.۲۲ است. همچنین حداقل سن ثبت‌شده ۰.۰۸ سال و حداکثر سن ۸۰ سال است. بیشینه BMI برابر ۹۵.۶۹ و بیشینه سطح گلوکز خون برابر ۳۰۰ گزارش شده است.


۲.۱.۳ توزیع ویژگی‌ها و هدف

در شکل ۱، هیستوگرام تمامی ویژگی‌ها پس از کدگذاری به تصویر کشیده شده است. پس از پاک‌سازی داده‌ها و بازطبقه‌بندی ویژگی سابقه مصرف سیگار، تعداد افراد در هر دسته به‌صورت زیر بود:

-non-smoker: 67,276 نفر
-current: 9,197 نفر
-past_smoker: 19,655 نفر

همچنین از نظر جنسیت، پس از حذف ۱۸ نمونه با مقدار "Other"، تعداد زنان برابر ۵۶,۱۶۱ و تعداد مردان برابر ۳۹,۹۶۷ بود. در ویژگی سابقه فشارخون بالا، ۸۸,۶۶۷ نفر فاقد سابقه فشارخون بالا و ۷,۴۶۱ نفر دارای سابقه فشارخون بالا بودند. در ویژگی

سابقه بیماری قلبی نیز ۹۲,۲۰۵ نفر فاقد سابقه بیماری قلبی و ۳,۹۲۳ نفر دارای سابقه بیماری قلبی بودند. توزیع هدف نیز شامل ۸۷,۶۴۶ نمونه غیر دیابتی و ۸,۴۸۲ نمونه دیابتی بود.



شکل ۱ - هیستوگرام توزیع تمامی ویژگی‌ها و هدف در دیتافریم df1.

۲.۳ پیش‌پردازش داده‌ها

۱.۲.۳ پاک‌سازی و کدگذاری

حذف تکراری و null: سطرهای تکراری (duplicated()) و سطرهای حاوی مقادیر گمشده (isnull()) حذف شدند. کدگذاری جنسیت: ۱۸ سطر با جنسیت "Other" (به دلیل تعداد ناچیز) حذف شدند و سپس Female=0 و Male=1 تعیین شد (جدول ۳).

جدول ۳ - نمایش ۱۰ سطر اول دیتافریم پس از کدگذاری ویژگی جنسیت.

Head after gender/smoking recoding:									
	gender	age	hypertension	heart_disease	smoking_history	bmi	HbA1c_level	blood_glucose_level	diabetes
0	0	80.0	0	1	non-smoker	25.19	6.6	140	0
1	0	54.0	0	0	non-smoker	27.32	6.6	80	0
2	1	28.0	0	0	non-smoker	27.32	5.7	158	0
3	0	36.0	0	0	current	23.45	5.0	155	0
4	1	76.0	1	1	current	20.14	4.8	155	0
5	0	20.0	0	0	non-smoker	27.32	6.6	85	0
6	0	44.0	0	0	non-smoker	19.31	6.5	200	1
7	0	79.0	0	0	non-smoker	23.86	5.7	85	0
8	1	42.0	0	0	non-smoker	33.64	4.8	145	0
9	0	32.0	0	0	non-smoker	27.32	5.0	100	0

بازطبقه‌بندی مصرف سیگار: ۶ رسته اولیه (never, No Info, current, former, ever, not current) به ۳ رسته

کلی تبدیل شدند:

non-smoker ← never + No Info

current ← current

past_smoker ← former + ever + not current

One-Hot Encoding: رسته‌های جدید مصرف سیگار با One-Hot Encoder به ۳ ستون باینری (current, non-) تبدیل شدند و دیتافریم نهایی df1 تولید شد (جدول ۴).

(smoker, past_smoker) تبدیل شدند و دیتافریم نهایی df1 تولید شد (جدول ۴).

جدول ۴ – نمایش ۱۰ سطر اول دیتافریم df1 پس از One-Hot Encoding ویژگی سابقه مصرف سیگار.

Head of processed dataframe (df1):

	current	non-smoker	past_smoker	gender	age	hypertension	heart_disease	bmi	HbA1c_level	blood_glucose_level	diabetes
0	0.0	1.0	0.0	0.0	80.0	0.0	1.0	25.19	6.6	140.0	0.0
1	0.0	1.0	0.0	0.0	54.0	0.0	0.0	27.32	6.6	80.0	0.0
2	0.0	1.0	0.0	1.0	28.0	0.0	0.0	27.32	5.7	158.0	0.0
3	1.0	0.0	0.0	0.0	36.0	0.0	0.0	23.45	5.0	155.0	0.0
4	1.0	0.0	0.0	1.0	76.0	1.0	1.0	20.14	4.8	155.0	0.0
5	0.0	1.0	0.0	0.0	20.0	0.0	0.0	27.32	6.6	85.0	0.0
6	0.0	1.0	0.0	0.0	44.0	0.0	0.0	19.31	6.5	200.0	1.0
7	0.0	1.0	0.0	0.0	79.0	0.0	0.0	23.86	5.7	85.0	0.0
8	0.0	1.0	0.0	1.0	42.0	0.0	0.0	33.64	4.8	145.0	0.0
9	0.0	1.0	0.0	0.0	32.0	0.0	0.0	27.32	5.0	100.0	0.0

گفتنی است که کدگذاری One-Hot ویژگی smoking_history در دیتافریم df1 برای تحلیل اکتشافی، رسم نمودارها و نمایش توزیع ویژگی‌ها انجام شد. اما در مرحله مدل‌سازی و اعمال SMOTENC، ویژگی smoking_history ابتدا به یک کد عددی موقت با نام smoking_code تبدیل شد تا بتوان آن را به‌عنوان یک ویژگی دسته‌ای به روش SMOTENC معرفی کرد. پس از متوازن‌سازی داده‌های آموزشی، این ویژگی دوباره به سه ستون One-Hot شامل current، non-smoker و past_smoker تبدیل شد.

۲.۲.۳ تقسیم داده و متوازن‌سازی

داده‌ها با استفاده از تابع train_test_split به دو بخش آموزش و آزمون تقسیم شدند. ۷۵٪ داده‌ها برای آموزش و ۲۵٪ برای آزمون در نظر گرفته شد. همچنین به‌منظور حفظ نسبت کلاس‌ها در هر دو بخش، از پارامتر stratify=Y استفاده شد. در نتیجه، تعداد نمونه‌های آموزشی برابر ۷۲,۰۹۶ و تعداد نمونه‌های آزمون برابر ۲۴,۰۳۲ شد.

از آنجا که دیتاست دارای عدم‌توازن شدید میان کلاس‌های دیابتی و غیر دیابتی بود، متوازن‌سازی تنها روی داده‌های آموزشی انجام شد. با توجه به وجود ویژگی‌های دسته‌ای مانند سابقه مصرف سیگار، جنسیت، سابقه فشارخون بالا و سابقه بیماری قلبی، به‌جای SMOTE معمولی از روش SMOTENC استفاده شد. این روش برای داده‌هایی مناسب است که ترکیبی از ویژگی‌های عددی و دسته‌ای دارند.


در این مرحله، ویژگی‌های smoking_code، gender، hypertension و heart_disease به‌عنوان ویژگی‌های دسته‌ای به SMOTENC معرفی شدند و ویژگی‌های age، bmi، HbA1c_level و blood_glucose_level به‌عنوان ویژگی‌های عددی در نظر گرفته شدند. قبل از اعمال SMOTENC، ویژگی‌های عددی با استفاده از StandardScaler استانداردسازی شدند. این کار اهمیت دارد، زیرا روش‌های مبتنی بر فاصله مانند SMOTE و SMOTENC نسبت به مقیاس ویژگی‌ها حساس هستند. پس از اعمال SMOTENC، تعداد نمونه‌های آموزشی از ۷۲,۰۹۶ به ۱۳۱,۴۶۸ افزایش یافت.

۳.۳ تحلیل همبستگی و انتخاب ویژگی

۱.۳.۳ ماتریس همبستگی

در شکل ۲، ماتریس همبستگی پیرسون برای ویژگی‌های عددی و متغیر هدف diabetes رسم شده است. این همبستگی‌ها بر اساس داده آموزشی استانداردسازی شده و متوازن‌سازی شده با SMOTENC محاسبه شده‌اند. نتایج نشان داد که ویژگی HbA1c_level با ضریب همبستگی ۰.۵۹۸۶۹۵ بیشترین ارتباط خطی را با متغیر هدف دارد. پس از آن، blood_glucose_level با ضریب ۰.۵۴۱۳۳۰، age با ضریب ۰.۴۹۸۹۰۷ و bmi با ضریب ۰.۳۴۸۱۷۲ در رتبه‌های بعدی قرار گرفتند.


بنابراین، ویژگی‌های HbA1c_level، blood_glucose_level و age بیشترین ارتباط را با ابتلا به دیابت نشان دادند.



شکل ۲ - ماتریس همبستگی (Correlation Heatmap) ویژگی‌های عددی با هدف diabetes.

برای بررسی تأثیر ویژگی‌های دسته‌ای، میانگین مقدار متغیر هدف diabetes در هر گروه از ویژگی‌های جنسیت و سابقه مصرف سیگار محاسبه شد. از آنجا که مقدار diabetes=1 نشان‌دهنده ابتلا به دیابت است، میانگین این متغیر در هر گروه را می‌توان به عنوان احتمال تقریبی ابتلا به دیابت در همان گروه تفسیر کرد. نتایج شکل ۳ نشان می‌دهد که احتمال ابتلا به دیابت در مردان حدود ۱۰.۱٪ و در زنان حدود ۷.۹٪ است؛ بنابراین در این داده‌ها، مردان نسبت به زنان احتمال ابتلای بیشتری دارند. همچنین در ویژگی سابقه مصرف سیگار، افراد غیرسیگاری با احتمال حدود ۷.۱٪ کمترین مقدار، افراد سیگاری فعلی با احتمال حدود ۱۰.۳٪ مقدار میانی، و افراد دارای سابقه مصرف سیگار با احتمال حدود ۱۴.۰٪ بیشترین احتمال ابتلا به دیابت را نشان می‌دهند.


با این حال، مقایسه این نتایج با تحلیل همبستگی و اهمیت ویژگی‌ها نشان می‌دهد که اثر ویژگی‌های دسته‌ای مانند جنسیت و سابقه مصرف سیگار نسبت به ویژگی‌های عددی و آزمایشگاهی، به‌ویژه HbA1c_level، blood_glucose_level و age، ضعیف‌تر است. این موضوع با نتایج انتخاب ویژگی توسط مدل ExtraTrees نیز همخوانی دارد؛ زیرا سه ویژگی نهایی انتخاب‌شده شامل سن، سطح HbA1c و سطح قند خون بودند.



شکل ۳ - مقایسه احتمال ابتلا به دیابت بر اساس جنسیت (چپ) و سابقه مصرف سیگار (راست).

۲.۳.۳ انتخاب ویژگی با ExtraTrees

برای کاهش ابعاد و حذف ویژگی‌های کم‌اهمیت، مدل ExtraTreesClassifier با ۱۰۰ درخت آموزش داده شد و امتیاز اهمیت هر ویژگی محاسبه گردید. سپس با استفاده از SelectFromModel و آستانه برابر با میانگین اهمیت‌ها، ویژگی‌هایی که اهمیت آن‌ها بالاتر از میانگین بود انتخاب شدند (شکل ۴).



شکل ۴ - نمودار اهمیت ویژگی‌ها (Feature Importance) با استفاده از ExtraTreesClassifier. خط افقی آبی نشان‌دهنده میانگین امتیازها است.

اهمیت ویژگی‌ها به صورت زیر به دست آمد:

```
current: 0.00146
non-smoker: 0.00511
past_smoker: 0.00596
gender: 0.00660
age: 0.18690
hypertension: 0.03697
heart_disease: 0.01694
bmi: 0.09150
HbA1c_level: 0.35044
blood_glucose_level: 0.29812
```

با توجه به اینکه میانگین اهمیت‌ها برابر با ۰.۱۰ بود، تنها سه ویژگی age، HbA1c_level و blood_glucose_level دارای امتیاز بالاتر از میانگین بودند و به عنوان ویژگی‌های نهایی انتخاب شدند. در این مرحله، شاخص ویژگی‌ها مطابق ترتیب ستون‌های نهایی شامل current، non-smoker، past_smoker، gender، age، hypertension، heart_disease، bmi، HbA1c_level و blood_glucose_level تفسیر شد؛ بنابراین ویژگی‌های شماره ۴، ۸ و ۹ به ترتیب معادل age، HbA1c_level و blood_glucose_level هستند. در نتیجه، فضای ویژگی از ۱۰ ویژگی به ۳ ویژگی کاهش یافت. پس از انتخاب ویژگی، ابعاد داده آموزشی و آزمون به ترتیب به صورت Xtr: (131468, 3) و Xte: (24032, 3) درآمد.

۴. نتایج و بحث

در این تحقیق ۷ طبقه‌بند (K-Nearest Neighbors (KNN)، Gaussian Naive Bayes (GaussianNB)، Support Vector Machine (SVM)، Logistic Regression، AdaBoost، Decision Tree و Multi-layer Perceptron (MLPClassifier)) مورد استفاده قرار گرفته‌اند. تعدادی دیگر، پارامترها یا هایپرپارامترهای آن‌ها تنظیم یا انتخاب شده‌اند. به عنوان مثال، برای انتخاب مقدار مناسب K همسایه نزدیک مورد استفاده در طبقه‌بند KNN، داده آموزشی به دو بخش آموزش و اعتبارسنجی تقسیم شد و مقادیر K از ۱ تا ۱۰ مورد بررسی قرار گرفتند. برخلاف روش‌هایی که مقدار K را بر اساس داده آزمون انتخاب می‌کنند، در این تحقیق انتخاب K فقط بر اساس داده اعتبارسنجی انجام شد تا از نشت اطلاعات داده آزمون به فرآیند آموزش جلوگیری شود (شکل (۵)).

نتایج نشان داد که $K=1$ کمترین نرخ خطای اعتبارسنجی را دارد. بنابراین، مدل نهایی KNN با مقدار $K=1$ روی کل داده آموزشی آموزش داده شد.

KNN ($K=1$) - Train acc: 0.9772 Test acc: 0.9499


برای کلاس غیر دیابتی:

Precision = 0.97
Recall = 0.97
F1-score = 0.97

برای کلاس دیابتی:

Precision = 0.72
Recall = 0.71
F1-score = 0.72

دقت کلی مدل برابر با ۹۴.۹۹ درصد به دست آمد.



شکل ۵ - نحوه مشخص کردن K همسایه نزدیک مورد استفاده در طبقه‌بند KNN با توجه به کمترین نرخ خطای اعتبارسنجی. در ادامه، نتایج حاصل از آموزش و ارزیابی ۷ طبقه‌بند مختلف به ترتیب ارائه شده است. عملکرد هر یک از این مدل‌ها با استفاده از معیارهای Accuracy، Precision، Recall و ماتریس درهم‌ریختگی مورد بررسی قرار گرفته است تا در نهایت با مقایسه نتایج، کارآمدترین مدل جهت تشخیص بیماری انتخاب گردد.

Gaussian Naive Bayes Classifier


GaussianNB - Train acc: 0.8556911187513311 Test acc: 0.8766228362183754

	precision	recall	f1-score	support
0	0.98	0.88	0.93	21912
1	0.40	0.82	0.54	2120
accuracy			0.88	24032
macro avg	0.69	0.85	0.73	24032
weighted avg	0.93	0.88	0.89	24032

=== Overall classifier results so far ===

	model	train_acc	test_acc	relative_to_best
0	GaussianNB	0.855691	0.876623	1.0

=====



شکل ۶ - ماتریس درهم‌ریختگی نرمال‌شده مدل مبتنی بر GaussianNB.

KNeighbors Classifier

Best K according to validation error rate: K=1


KNN (K=1) - Train acc: 0.9772 Test acc: 0.9499

	precision	recall	f1-score	support
0	0.97	0.97	0.97	21912
1	0.72	0.71	0.72	2120
accuracy			0.95	24032
macro avg	0.84	0.84	0.84	24032
weighted avg	0.95	0.95	0.95	24032

=== Overall classifier results so far ===

	model	train_acc	test_acc	relative_to_best
0	GaussianNB	0.855691	0.876623	0.923
1	KNN(K=1)	0.977226	0.949900	1.000

=====



شکل ۷ - ماتریس درهم‌ریختگی نرمال‌شده مدل مبتنی بر KNN.

Support Vector Machine


SVM (RBF) - Train acc: 0.8938448900112574 Test acc: 0.8528212383488681

	precision	recall	f1-score	support
0	0.99	0.85	0.91	21912
1	0.37	0.92	0.52	2120
accuracy			0.85	24032
macro avg	0.68	0.88	0.72	24032
weighted avg	0.94	0.85	0.88	24032

=== Overall classifier results so far ===

	model	train_acc	test_acc	relative_to_best
0	GaussianNB	0.855691	0.876623	0.923
1	KNN(K=1)	0.977226	0.949900	1.000
2	SVM (RBF)	0.893845	0.852821	0.898

=====



شکل ۸ - ماتریس درهم‌ریختگی نرمال شده مدل مبتنی بر SVM.

Logistic Regression


Logistic Regression - Train acc: 0.8697629841482338 Test acc: 0.8686334886817576

	precision	recall	f1-score	support
0	0.98	0.87	0.92	21912
1	0.39	0.86	0.54	2120
accuracy			0.87	24032
macro avg	0.69	0.86	0.73	24032
weighted avg	0.93	0.87	0.89	24032

=== Overall classifier results so far ===

	model	train_acc	test_acc	relative_to_best
0	GaussianNB	0.855691	0.876623	0.923
1	KNN(K=1)	0.977226	0.949900	1.000
2	SVM (RBF)	0.893845	0.852821	0.898
3	Logistic Regression	0.869763	0.868633	0.914

=====



شکل ۹ - ماتریس درهم‌ریختگی نرمال‌شده مدل مبتنی بر Logistic Regression.


AdaBoost Classifier

AdaBoost - Train acc: 0.9604694678552956 Test acc: 0.9528961384820239

	precision	recall	f1-score	support
0	0.97	0.98	0.97	21912
1	0.74	0.72	0.73	2120
accuracy			0.95	24032
macro avg	0.86	0.85	0.85	24032
weighted avg	0.95	0.95	0.95	24032

=== Overall classifier results so far ===

	model	train_acc	test_acc	relative_to_best
0	GaussianNB	0.855691	0.876623	0.920
1	KNN(K=1)	0.977226	0.949900	0.997
2	SVM (RBF)	0.893845	0.852821	0.895
3	Logistic Regression	0.869763	0.868633	0.912
4	AdaBoost	0.960469	0.952896	1.000



شکل ۱۰ - ماتریس درهم‌ریختگی نرمال‌شده مدل مبتنی بر AdaBoost.

Decision Tree Classifier


Decision Tree - Train acc: 0.9839048285514346 Test acc: 0.9675016644474035

	precision	recall	f1-score	support
0	0.97	0.99	0.98	21912
1	0.93	0.69	0.79	2120
accuracy			0.97	24032
macro avg	0.95	0.84	0.89	24032
weighted avg	0.97	0.97	0.97	24032

=== Overall classifier results so far ===

	model	train_acc	test_acc	relative_to_best
0	GaussianNB	0.855691	0.876623	0.906
1	KNN(K=1)	0.977226	0.949900	0.982
2	SVM (RBF)	0.893845	0.852821	0.881
3	Logistic Regression	0.869763	0.868633	0.898
4	AdaBoost	0.960469	0.952896	0.985
5	Decision Tree	0.983905	0.967502	1.000

=====



شکل ۱۱ - ماتریس درهم‌ریختگی نرمال‌شده مدل مبتنی بر Decision Tree.

Multi-layer Perceptron classifier

MLPClassifier - Train acc: 0.9104877232482429 Test acc: 0.90021637816245


	precision	recall	f1-score	support
0	0.98	0.91	0.94	21912
1	0.46	0.84	0.60	2120
accuracy			0.90	24032
macro avg	0.72	0.87	0.77	24032
weighted avg	0.94	0.90	0.91	24032

=== Overall classifier results so far ===

	model	train_acc	test_acc	relative_to_best
0	GaussianNB	0.855691	0.876623	0.906
1	KNN(K=1)	0.977226	0.949900	0.982
2	SVM (RBF)	0.893845	0.852821	0.881
3	Logistic Regression	0.869763	0.868633	0.898

4	AdaBoost	0.960469	0.952896	0.985
5	Decision Tree	0.983905	0.967502	1.000
6	MLPClassifier	0.910488	0.900216	0.930

=====



شکل ۱۲ - ماتریس درهم‌ریختگی نرمال‌شده مدل مبتنی بر MLPClassifier.

=== FINAL CLASSIFIER SUMMARY ===

=== Overall classifier results so far ===

	model	train_acc	test_acc	relative_to_best
0	GaussianNB	0.855691	0.876623	0.906
1	KNN(K=1)	0.977226	0.949900	0.982
2	SVM (RBF)	0.893845	0.852821	0.881
3	Logistic Regression	0.869763	0.868633	0.898
4	AdaBoost	0.960469	0.952896	0.985
5	Decision Tree	0.983905	0.967502	1.000
6	MLPClassifier	0.910488	0.900216	0.930

=====

۱.۴ جمع‌بندی و مقایسه عملکرد مدل‌ها

با تحلیل نتایج حاصل از هفت طبقه‌بند مورد استفاده، مشاهده می‌شود که عملکرد مدل‌ها بسته به معیار ارزیابی متفاوت است. اگر معیار اصلی دقت کلی یا Accuracy باشد، مدل Decision Tree با دقت آزمون ۹۶.۷۵٪ بهترین عملکرد را در میان تمام مدل‌ها داشته است. پس از آن، AdaBoost با دقت ۹۵.۲۹٪ و KNN با مقدار $K=1$ و دقت ۹۴.۹۹٪ قرار دارند.

با این حال، در مسائل پزشکی، به‌خصوص در مسئله تشخیص بیماری، تنها Accuracy معیار کافی و قابل اتکا نیست. دلیل این موضوع آن است که در چنین کاربردهایی خطای منفی کاذب، یعنی تشخیص اشتباه یک بیمار واقعی به‌عنوان فرد سالم، می‌تواند خطرناک‌تر از خطای مثبت کاذب باشد. بنابراین معیار Recall برای کلاس دیابت اهمیت زیادی دارد.

از نظر Recall کلاس دیابت، مدل SVM با کرنل RBF بهترین عملکرد را داشته و توانسته است ۹۲٪ از بیماران دیابتی را شناسایی کند. پس از آن، Logistic Regression با Recall برابر ۸۶٪، MLPClassifier با Recall برابر ۸۴٪ و GaussianNB با Recall برابر ۸۲٪ قرار دارند. البته مدل SVM دارای Precision پایین‌تری برابر با ۰.۳۷ است؛ یعنی تعدادی از افراد سالم را نیز به‌اشتباه دیابتی تشخیص داده است. با این وجود، در کاربردهای غربالگری، چنین رفتاری می‌تواند قابل قبول باشد، زیرا افراد مشکوک می‌توانند برای آزمایش‌های تکمیلی ارجاع داده شوند.

از طرف دیگر، مدل Decision Tree اگرچه Recall پایین‌تری برای کلاس دیابت دارد و تنها ۶۹٪ بیماران را شناسایی کرده است، اما Precision آن برای کلاس دیابت برابر ۰.۹۳ است. این بدان معناست که زمانی که مدل Decision Tree

فردی را دیابتی تشخیص می‌دهد، احتمال درست بودن این پیش‌بینی بسیار زیاد است. همچنین این مدل بیشترین F1-score را برای کلاس دیابت، یعنی ۰.۷۹، به دست آورده است. بنابراین Decision Tree از نظر عملکرد کلی، تعادل بین Precision و F1-score و دقت آزمون، بهترین مدل محسوب می‌شود.

مدل AdaBoost نیز عملکردی متعادل دارد. این مدل با Accuracy برابر ۹۵.۲۹٪، Precision برابر ۰.۷۴، Recall برابر ۰.۷۲ و F1-score برابر ۰.۷۳ برای کلاس دیابت، یکی از مدل‌های قابل قبول و پایدار در این تحقیق است. در نتیجه، اگر هدف اصلی سیستم، تشخیص کلی با دقت بالا و خطای کمتر در پیش‌بینی مثبت باشد، مدل Decision Tree مناسب‌ترین گزینه است. اما اگر هدف سیستم غربالگری اولیه و شناسایی حداکثری بیماران احتمالی باشد، مدل SVM با کرنل RBF به دلیل Recall بالاتر، گزینه مناسب‌تری خواهد بود.

۵. نتیجه‌گیری و کارهای آتی

در این تحقیق، داده‌های مربوط به ۱۰۰,۰۰۰ مراجعه‌کننده برای پیش‌بینی ابتلا به دیابت مورد استفاده قرار گرفت. پس از حذف رکوردهای تکراری و حذف نمونه‌های دارای مقدار "Other" در ویژگی جنسیت، تعداد داده‌های پاک‌سازی شده به ۹۶,۱۲۸ رکورد رسید. سپس ویژگی‌های دسته‌ای کدگذاری و ویژگی‌های عددی استانداردسازی شدند. پس از تقسیم داده‌ها به دو بخش آموزش و آزمون، متوازن‌سازی تنها روی داده‌های آموزشی و با استفاده از روش SMOTENC انجام شد که در نتیجه آن تعداد نمونه‌های آموزشی از ۷۲,۰۹۶ به ۱۳۱,۴۶۸ افزایش یافت. با استفاده از روش ExtraTreesClassifier برای انتخاب ویژگی، سه ویژگی age، HbA1c_level و blood_glucose_level به عنوان مهم‌ترین ویژگی‌ها شناسایی شدند.

در مرحله مدل‌سازی، ۷ طبقه‌بند Decision Tree، AdaBoost، Logistic Regression، SVM، KNN، GaussianNB و MLPClassifier آموزش داده و ارزیابی شدند. نتایج نشان داد که مدل Decision Tree با دقت آزمون ۹۶.۷۵٪، Precision برابر ۰.۹۳ و F1-score برابر ۰.۷۹ برای کلاس دیابت، بهترین عملکرد کلی را در میان مدل‌های مورد بررسی دارد. این مدل به‌ویژه از نظر اطمینان در پیش‌بینی افراد دیابتی عملکرد بسیار خوبی نشان داد.

با این حال، در کاربردهای غربالگری پزشکی، معیار Recall اهمیت ویژه‌ای دارد؛ زیرا عدم شناسایی بیمار واقعی می‌تواند پیامدهای خطرناکی داشته باشد. از این دیدگاه، مدل SVM با کرنل RBF با Recall برابر ۹۲٪ برای کلاس دیابت، حساس‌ترین مدل در تشخیص بیماران واقعی بود. اگرچه Precision این مدل پایین‌تر است و ممکن است برخی افراد سالم را به اشتباه مشکوک به دیابت تشخیص دهد، اما در سامانه‌های غربالگری این موضوع می‌تواند قابل قبول باشد، زیرا افراد مشکوک برای بررسی‌های تکمیلی ارجاع داده می‌شوند.

بنابراین، نتیجه نهایی این پژوهش را می‌توان به دو صورت بیان کرد: مدل Decision Tree بهترین مدل از نظر عملکرد کلی و تعادل معیارها است، در حالی که مدل SVM مناسب‌ترین مدل برای کاربردهای غربالگری و شناسایی حداکثری بیماران دیابتی محسوب می‌شود.

در کارهای آتی، می‌توان با استفاده از داده‌های کامل‌تر پزشکی، شامل قد، وزن، دور شکم، سابقه خانوادگی، میزان فعالیت بدنی، رژیم غذایی و سوابق آزمایشگاهی دقیق‌تر، عملکرد مدل‌ها را بهبود داد. همچنین استفاده از روش‌های تنظیم هایپرپارامتر، اعتبارسنجی متقابل، مدل‌های ترکیبی پیشرفته و روش‌های توضیح‌پذیری مدل مانند SHAP می‌تواند به افزایش دقت و تفسیرپذیری سامانه کمک کند.

مراجع و منابع مورد استفاده

- [1] A. Mujumdar and V. Vaidehi, "Diabetes prediction using machine learning algorithms," Procedia Computer Science, vol. 165, pp. 292-299, 2019.
- [2] T. Sasada, Z. Liu, T. Baba, K. Hatano, and Y. Kimura, "A resampling method for imbalanced datasets considering noise and overlap," Procedia Computer Science, vol. 176, pp. 420-429, 2020.
- [3] <https://www.kaggle.com/code/gastonpascaltonguino/diabetes-dataset-eda-modeling>